МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА ФРАНКА

Факультет електроніки та комп’ютерних технологій

ЗВІТ

З ЛАБОРАТОРНОЇ РОБОТИ №1

з дисципліни «Методи та технології інженерії даних»

на тему: «Ініціалізація проєкту та первинне дослідження джерел даних»

Виконав:
Студент 3 курсу
групи ФЕП-34
Полянський Тимотей

Перевірив:
ас. Фостяк Маркіян Романович

Львів 2026

1. Мета роботи та конфігурація середовища

Мета роботи: налаштувати ізольоване середовище Python і Git-репозиторій індивідуального проєкту; навчитися зчитувати CSV за допомогою `pandas`, досліджувати структуру джерел, визначати grain, кандидатні ключі та зв'язки, виявляти проблеми якості й документувати їх, не змінюючи первинних файлів.

- Студент: Полянський Тимотей, група ФЕП-34; `student_id: S08` (пакет `S08-LAB01-BASE-V1`).
- Вхідний архів: `cityflow_S08_base_v1.zip`, SHA-256 `8a8eb3777248c41e1ffc424ca055ecde9ece81efe5a5e93e4d464bede4b661ac` (збігається з наданою викладачем); файли звірено з `PACKAGE_INFO.json`.
- Середовище: Omarchy (Arch Linux, Wayland), fish, Neovim, tmux; контроль версій — git, lazygit, gh.
- Python `3.14.7`, менеджер `uv`, pandas `3.0.6`, matplotlib, jupytext (залежності зафіксовано в `pyproject.toml` і `uv.lock`).
- Гілка `lab/01-init-profiling`, тег `lab-01-v1`.
- Репозиторій: https://github.com/TimoteyPolyanskiy/data-engineering-cityflow-S08
- Pull Request: https://github.com/TimoteyPolyanskiy/data-engineering-cityflow-S08/pull/1

2. Джерела даних, рівень деталізації та ключі

Досліджено чотири файли пакета. Унікальність ключів і зв'язки нижче **перевірено** на даних.

Файл	Ключ	Один рядок =	Зв'язки (перевірено)	Унікальних ID / рядків
`customers.csv`	`customer_id`	один клієнт	батько для `orders.customer_id`	800 / 801
`merchants.csv`	`merchant_id`	один заклад-партнер	батько для `products` і `orders`	42 / 43
`products.csv`	`product_id`	один товар закладу	`merchant_id → merchants` (відсутніх батьків: 1)	533 / 534
`orders.csv`	`order_id`	одне замовлення	`customer_id → customers` (1), `merchant_id → merchants` (1)	6 000 / 6 001

3. Підсумкова діагностична таблиця

Усі числа обчислено в `notebooks/lab01/01_source_profiling.py` (виконаний як `.ipynb`). Рахуються **рядки файла** (разом із дублікатами); «унікальні ID» — кількість різних значень ключа. Початкові CSV лежать у `data/raw/base_v1/` без змін.

Файл	Рядків	Колонок	Унікальних ID	Повних дублікатів	Пропущених клітинок	Часове поле	Діапазон дат	Некоректних дат
`customers.csv`	801	8	800	1	5	`registered_at`	2024-03-10 — 2026-08-29	0
`merchants.csv`	43	7	42	1	0	`opened_at`	2019-09-07 — 2025-07-19	0
`products.csv`	534	7	533	1	0	`updated_at`	2025-08-02 — 2026-08-30	0
`orders.csv`	6 001	10	6 000	1	0	`created_at`	2025-09-01 — 2026-08-31	2

Пропуск — порожнє поле; некоректна дата — непорожнє значення, що не є ISO 8601. У `orders.created_at` таких значень 2: `04/09/2025 11:32` (`S08-O0000044`); `2026-19-45 25:61:00` (`S08-O0003385`). Значення `DD/MM/YYYY` — лише припущення про формат; початкові значення збережено.

4. Ключові перевірки: фрагменти коду й результати

Повний код — у ноутбуці; тут лише перевірки, на яких тримаються висновки. Усі результати нижче взято з `docs/lab01/metrics.json`.

Кандидатний ключ, повні дублікати й конфлікти ключа (розділ 3.3 ноутбука):

```
full = frame.duplicated(keep=False)                    # усі колонки однакові
key_dup = frame.duplicated(subset=[key], keep=False)   # повторюється лише ключ
conflicts = key_dup & ~full                            # той самий ключ, різні значення
```

Результат: `customers` — унікальних ID 800 з 801 рядків, повних дублікатів 1, конфліктів 0; `merchants` — унікальних ID 42 з 43 рядків, повних дублікатів 1, конфліктів 0; `products` — унікальних ID 533 з 534 рядків, повних дублікатів 1, конфліктів 0; `orders` — унікальних ID 6 000 з 6 001 рядків, повних дублікатів 1, конфліктів 0.

Пропуск, порожнє поле й пробіли (розділ 3.2): файл додатково читається як текст, бо `pd.read_csv()` перетворює порожнє поле на `NaN`:

```
t = pd.read_csv(path, dtype=str, keep_default_na=False)  # порожнє поле лишається ""
stripped = t[col].str.strip()
empty_field = (t[col] == "").sum()
whitespace_only = ((stripped == "") & (t[col] != "")).sum()
edge_whitespace = ((t[col] != stripped) & (stripped != "")).sum()
```

«Пропущені клітинки» — це `NaN` після `pd.read_csv()`. Щоб відрізнити порожнє поле від рядка з пробілів, файли прочитано ще й як текст: `customers.csv` / `phone`: NaN — 5, порожніх полів — 5, лише з пробілів — 0, з пробілами по краях — 0; `customers.csv` / `city`: NaN — 0, порожніх полів — 0, лише з пробілів — 0, з пробілами по краях — 1; `products.csv` / `category`: NaN — 0, порожніх полів — 0, лише з пробілів — 0, з пробілами по краях — 1. Отже, усі 5 `NaN` — це порожні поля; рядків лише з пробілів немає. Пробіли по краях не дають `NaN`, тому в цій колонці таблиці їх не видно.

Пропущені й некоректні дати (розділ 3.4):

```
parsed = pd.to_datetime(raw_col, format="ISO8601", errors="coerce", utc=True)
empty = raw_col.str.strip() == ""                       # пропуск
invalid = parsed.isna() & ~empty                        # значення є, але не ISO 8601
```

Результат: пропущених дат: `customers` — 0, `merchants` — 0, `products` — 0, `orders` — 0; некоректних — лише в `orders.created_at`: `04/09/2025 11:32` (`S08-00000044`); `2026-19-45 25:61:00` (`S08-00003385`). Початкові значення не змінюються: розбір робиться в окремій змінній.

Посилання на відсутні батьківські записи (розділ 3.6):

```
orphan_orders_customer = o[~o["customer_id"].isin(c["customer_id"])]
orphan_orders_merchant = o[~o["merchant_id"].isin(m["merchant_id"])]
orphan_products_merchant = p[~p["merchant_id"].isin(m["merchant_id"])]
```

Результат: `orders.customer_id` — `S08-00004825`; `orders.merchant_id` — `S08-00005136`; `products.merchant_id` — `S08-P000331`.

5. Діагностичні графіки

Графіки — підрахунки **записів** (разом із повним дублікатом), а не перевірені бізнес-показники; суми різних валют не об'єднувались.



Рисунок 1: Кількість записів про замовлення за статусами

Серед 6 001 записів (разом із повним дублікатом): `delivered` — 4 966, `cancelled` — 449, `partially_refunded` — 223, `refunded` — 198, `failed` — 162, `in_progress` — 3. Статус `delivered` переважає; активних замовлень мало, що відповідає історичному зрізу. Це підрахунки записів, а не перевірена виручка.

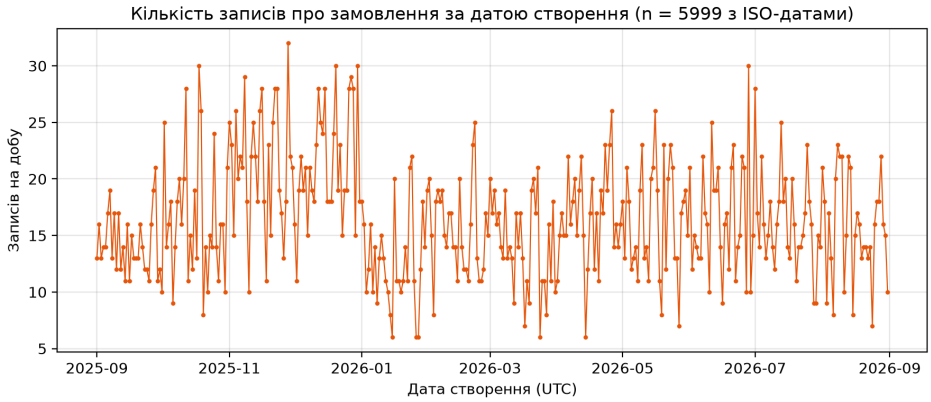


Рисунок 2: Кількість записів про замовлення за датою створення

За 365 діб кількість записів на добу: мінімум 6 (2026-01-15), максимум 32 (2025-11-28), медіана 16, середнє 16.4. Середній місячний рівень найвищий у 2025-11 (21.3) і найнижчий у 2026-01 (12.8); причину цих коливань дані пакета не пояснюють. Доба рахується за UTC; якщо групувати за київським часом, межі доби зсуваються й діапазон стає 5–32 записів. У графік не потрапили 2 записи з не-ISO датою.

6. Початкова схема проєкту (Architecture v0)

Суцільні лінії — реалізоване в Лабі 1; пунктиром позначено заплановані компоненти (API, база даних, сховище, трансформації, оркестрація, дашборд), які поки не реалізовано.

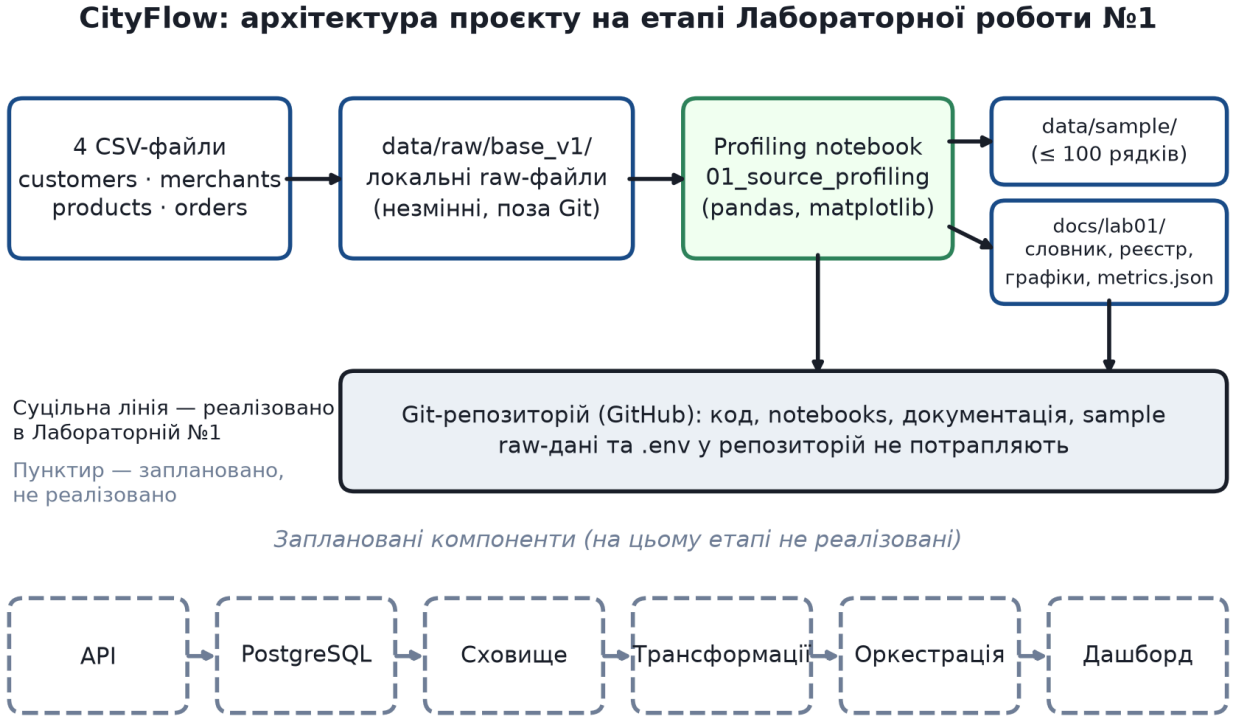


Рисунок 3: Схема потоків даних і Git-репозиторій на етапі Лаби 1

7. Реєстр проблем якості даних

Реєстр сформовано з результатів ноутбука (повна версія з прикладами — `docs/lab01/data_quality_findings.md`). **Підтверджене порушення** суперечить правилу, яке видно з даних; **потенційний ризик** потребує бізнес-уточнення.

№	Файл / поле	Тип	К-сть	Приклад ID	Проблема, вплив і дія
1	усі 4 CSV / ключ рядка	підтверджене порушення	4	S08-C000504, S08-M00009, S08-P000219…	повні дублікати рядків. Вплив: подвоєння записів; порушення PK у реляційній базі. Дія: залишити одну точну копію, решту позначити як duplicate (Лаба 2).
2	customers.csv / phone	потенційний ризик	5	S08-C000179, S08-C000180, S08-C000254…	порожнє поле телефону. Вплив: немає контакту для зв'язку; чи є телефон обов'язковим — припущення, джерело цього не каже. Дія: прийняти як допустимий пропуск, не підставляти 0 чи сурогат.
3	customers.csv / city	підтверджене порушення	1	S08-C000727	пробіли на початку/в кінці значення. Вплив: окремі написання однієї категорії (“ Lviv “ ≠ “Lviv”) ламають групування та порівняння. Дія: обрізати пробіли за явним правилом нормалізації, оригінал зберегти.
4	products.csv / category	підтверджене порушення	1	S08-P000195	пробіли на початку/в кінці значення. Вплив: окремі написання однієї категорії (“ Lviv “ ≠ “Lviv”) ламають групування та порівняння. Дія: обрізати пробіли за явним правилом нормалізації, оригінал зберегти.
5	products.csv / unit_price_uah	потенційний ризик	1	S08-P000074	ціна ≤ 0 в активного товару. Вплив: потребує бізнес-уточнення; нуль не завжди помилка (для неактивного товару допустимий). Дія: за контрактом Лаби 2 активний товар із ціною ≤ 0 відхиляється.
6	products.csv / merchant_id	підтверджене порушення	1	S08-P000331	посилання на відсутнього партнера. Вплив: порушення FK; INNER JOIN мовчки втратить товар. Дія: карантин з причиною ORPHAN_MERCHANT_FK.
7	orders.csv / customer_id	підтверджене порушення	1	S08-O0004825	посилання на відсутнього клієнта. Вплив: порушення FK; замовлення випаде зі звітів при INNER JOIN. Дія: карантин з причиною ORPHAN_CUSTOMER_FK.
8	orders.csv / merchant_id	підтверджене порушення	1	S08-O0005136	посилання на відсутнього партнера. Вплив: порушення FK. Дія: карантин з причиною ORPHAN_MERCHANT_FK.
9	orders.csv / currency	підтверджене порушення	1	S08-O0002449	код валюти поза UAH/USD/EUR: “UA H”. Вплив: розбиття групування за валютою; суми різних валют не можна об'єднувати. Дія: не виправляти здогадкою; відхиляти з причиною INVALID_CURRENCY.
10	orders.csv / created_at	підтверджене порушення	2	S08-O0000044, S08-O0003385	значення не є ISO 8601: “04/09/2025 11:32”; “2026-19-45 25:61:00”. Вплив: не приводяться до timestamptz автоматично; формат DD/MM/YYYY — лише припущення. Дія: DD/MM/YYYY HH:MM явно читати як UTC, неможливі дати відхиляти (Лаба 2).
11	orders.csv / total_amount	потенційний ризик	1	S08-O0001712	subtotal + delivery_fee − discount ≠ total_amount. Вплив: total_amount більший за обчислений на 137.17; причина невідома. Дія: лише діагностика, значення джерела не переписувати.

8. Висновки та обмеження

1. **Grain і ключі.** У всіх чотирьох файлах кандидатний ключ повторюється лише через повні дублікати (усього 4); конфліктів ключів 0.
2. **Зв'язки.** Знайдено 3 посилання на відсутні батьківські записи: S08-O0004825, S08-O0005136, S08-P000331.
3. **Значення, що потребують правил.** Код валюти UA H; 2 не-ISO дати; 1 товар із нульовою ціною (активний — потребує уточнення); 5 порожніх телефонів; пробіли по краях у city та category. Нулі в delivery_fee і discount_amount помилкою не вважаються.
4. **Діагностика сум.** У 1 замовленні subtotal + delivery_fee − discount не дорівнює total_amount (S08-O0001712).
5. **Обмеження.** Це пасивний аудит: нічого не виправлялось, СУБД не підключалась. Причини дублікатів, обов'язковість phone і формат DD/MM/YYYY — припущення; графіки показують записи, а не бізнес-показники.

9. Використання ШІ

Інструменти: Gemini і Claude. Gemini використано для чернеток коду профілювання (`pandas`, `jupytext`) і скрипта схеми `architecture_v0.png`; Claude — для перевірки ноутбука й звіту на відповідність вимогам методички. Поставлені завдання: підготувати чернетку коду перевірки порожніх полів, рядків із пробілів і некоректних дат; зіставити структуру звіту з вимогами методички. Власний внесок: поділ знахідок на підтверджені порушення й потенційні ризики, перевірка `is_active` для нульової ціни, відмова від непідтверджених пояснень причин дублікатів, самостійна вичитка звіту за методичкою. Перевірка: ноутбук виконано повністю (`jupytext --execute`); кількості рядків, ID дублікатів, відсутніх батьків, `UA H` і некоректних дат звірено з виведенням pandas на файлах пакета. Виправлена помилка: перша версія перевірки порожніх рядків шукала колонки типу `object`, а в pandas 3 текст має тип `str`, тому перевірка нічого не знаходила; помилку виявлено порівнянням з окремим підрахунком.

10. Відповіді на контрольні запитання

1. Що досліджує первинне профілювання і чим воно відрізняється від очищення?
Профілювання вимірює й описує стан сирих даних (типи, обсяги, пропуски, діапазони, дублікати, зв'язки) і нічого не змінює. Очищення змінює або відфільтровує дані; у цій роботі проблеми лише описано.

2. Що представляє рядок у кожному з ваших файлів? Як перевірити кандидатний ключ?
`customers` — клієнт, `merchants` — заклад-партнер, `products` — товар закладу, `orders` — замовлення. Ключ перевіряють порівнянням `df[key].nunique()` з `len(df)` та пошуком повторів `df.duplicated(subset=[key])`; для наших файлів повтори трапляються лише як повні дублікати.

3. Чим повний дублікат відрізняється від повторення ключа з іншими значеннями?
Повний дублікат — усі колонки збігаються (`df.duplicated()`), це та сама подія, записана двічі. Повтор ключа з різними значеннями — конфлікт: невідомо, яке значення правильне (помилка або нова версія без версіонування). Однакові назви чи суми самі по собі дублікатом не є. У пакеті конфліктів ключів немає.

4. Чим відрізняються пропуск, порожній рядок, нуль і некоректна дата?
Пропуск — значення відсутнє (`NaN`/`NULL`); порожнє поле CSV pandas за замовчуванням читає як `NaN`, тому для розрізнення файл читається ще й як текст. Порожній рядок `""` — текст довжини 0. Нуль — відоме число (нульова доставка нормальна, нульова ціна активного товару потребує уточнення). Некоректна дата — значення є, але не розбирається за очікуваним форматом; його зберігають і позначають, а не підміняють.

5. Як знайти замовлення, customer_id якого відсутній у файлі клієнтів?
У pandas: `orders[~orders["customer_id"].isin(customers["customer_id"])]`. В SQL: `LEFT JOIN customers ... WHERE customers.customer_id IS NULL`.

6. Навіщо зберігати незмінні raw-файли та перевіряти контрольну суму?
Щоб кожен результат можна було відтворити й перевірити: суму архіву звірено з викладацькою, а файли — з `PACKAGE_INFO.json`. Виправлення роблять кодом над копіями, а не вручну в джерелі.

7. Що потрібно для запуску notebook на іншому комп'ютері? Що не слід додавати до Git?
Версія Python, `pyproject.toml` і `uv.lock`, розпаковані raw-файли в `data/raw/base_v1/` та команда `uv sync`. У Git не додають повні raw-дані, `.venv/`, `.env`, архіви та службові файли Jupyter.

8. Які висновки підтверджені вашими даними, а які є припущеннями? Як перевірено допомогу ШІ?
Підтверджено даними: повних дублікатів 4 (`S08-C000504`, `S08-M00009`, `S08-P000219`…); порожніх телефонів 5; відсутніх батьків 3 (`S08-O0004825`, `S08-O0005136`, `S08-P000331`); код валюти `UA H`; 2 не-ISO дати. **Припущення:** що телефон необов'язковий; що `04/09/2025 11:32` означає 4 вересня; що нульова ціна активного товару — помилка (це правило навчального контракту Лаби 2, а не факт із даних); причина появи дублікатів. Поради ШІ перевірялись повторним обчисленням на файлах пакета й порівнянням із виведенням блокнота.